

Taivaanmekaniikka
Lineaarinen pienimmän neliösumman sovitus

Anni Järvenpää

16. lokakuuta 2015

1 Lineaarinen pienimmän neliösumman menetelmä

Lineaarisen pienimmän neliösumman menetelmän tavoitteena on sovittaa n muotoa (x_i, y_i) olevasta pisteestä koostuvaan havaintoaineistoon suora, joka edustaa pisteitä mahdollisimman hyvin. Tyypillisesti sovituksen hyvyttä mitataan pisteiden vertikaalisena etäisyytenä $|e|$ sovitetusta suorasta (merkitty sinisellä kuvassa 1). Pienimmän neliösumman menetelmässä näiden vertikaalisten poikkeamien neliöiden summa pyritään minimoimaan, siis etsimään funktion $f(x) = \beta_1 + \beta_2 x + \beta_3 x^2 + \dots + \beta_{m+1} x^m$ kertoimet $\beta_1 \dots \beta_{m+1}$ siten, että virhe S on mahdollisimman pieni, kun S on määritelty yhtälön 1 mukaisesti. [2]

$$S = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - f(x_i))^2 \quad (1)$$

Virheen minimiarvot löytyvät derivaatan nollakohdista:


$$\begin{aligned} \frac{\partial R^2}{\partial \beta_1} &= -2 \sum_{i=1}^n [y_i - (\beta_1 + \beta_2 x_i + \dots + \beta_{m+1} x_i^m)] = 0 \\ \frac{\partial R^2}{\partial \beta_2} &= -2 \sum_{i=1}^n [y_i - (\beta_1 + \beta_2 x_i + \dots + \beta_{m+1} x_i^m)] = 0 \\ &\vdots \\ \frac{\partial R^2}{\partial \beta_{m+1}} &= -2 \sum_{i=1}^n [y_i - (\beta_1 + \beta_2 x_i + \dots + \beta_{m+1} x_i^m)] = 0 \end{aligned}$$

Näistä saadaan edelleen

$$\begin{aligned} \beta_1 n + \beta_2 \sum_{i=1}^n x_i + \dots + \beta_{m+1} \sum_{i=1}^n x_i^m &= \sum_{i=1}^n y_i \\ \beta_1 \sum_{i=1}^n x_i + \beta_2 \sum_{i=1}^n x_i^2 + \dots + \beta_{m+1} \sum_{i=1}^n x_i^{m+1} &= \sum_{i=1}^n x_i y_i \\ \beta_1 \sum_{i=1}^n x_i^m + \beta_2 \sum_{i=1}^n x_i^{m+1} + \dots + \beta_{m+1} \sum_{i=1}^n x_i^{2m} &= \sum_{i=1}^n x_i^m y_i \end{aligned}$$

eli matriisimuodossa

$$\begin{bmatrix} n & \sum_{i=1}^n x_i & \dots & \sum_{i=1}^n x_i^m \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 & \dots & \sum_{i=1}^n x_i^{m+1} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^n x_i^m & \sum_{i=1}^n x_i^{m+1} & \dots & \sum_{i=1}^n x_i^{2m} \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_m \\ \beta_{m+1} \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n y_i \\ \sum_{i=1}^n x_i y_i \\ \vdots \\ \sum_{i=1}^n x_i^m y_i \end{bmatrix}$$



Kuva 1: Pistejoukko, johon sovitettu suora mustalla ja pisteiden vertikaaliset etäisyydet suorasta pisteinä.

Tämä voidaan edelleen kirjoittaa [1]

$$\begin{bmatrix} x_1^0 & x_1^2 & \dots & x_1^n \\ x_2^0 & x_2^2 & \dots & x_2^n \\ \vdots & \vdots & \ddots & \vdots \\ x_m^0 & x_m^2 & \dots & x_m^n \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_{m+1} \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} \quad (2)$$

Merkitään nyt

$$\mathbf{Y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, \quad \mathbf{X} = \begin{bmatrix} x_1^0 & x_1^2 & \dots & x_1^n \\ x_2^0 & x_2^2 & \dots & x_2^n \\ \vdots & \vdots & \ddots & \vdots \\ x_m^0 & x_m^2 & \dots & x_m^n \end{bmatrix} \quad \text{ja} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_m \end{bmatrix},$$

jolloin yhtälö 2 saadaan seuraavaan muotoon, josta voidaan helposti ratkaista $\boldsymbol{\beta}$. [1]

$$\begin{aligned} \mathbf{Y} &= \mathbf{X}\boldsymbol{\beta} & ||\mathbf{X}^T. \\ \mathbf{X}^T\mathbf{Y} &= \mathbf{X}^T\mathbf{X}\boldsymbol{\beta} & ||(\mathbf{X}^T\mathbf{X}\boldsymbol{\beta})^{-1} \\ \boldsymbol{\beta} &= (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{Y} \end{aligned} \quad (3)$$

Viitteet

- [1] Least squares fitting-polynomial. <http://mathworld.wolfram.com/LeastSquaresFittingPolynomial.html>. Luettu: 15.10.2015.
- [2] Peter J. Bickel. *Mathematical statistics: basic ideas and selected topics*. Holden-Day, Oakland, CA, 1977.

A Liittyvä liite.

Liian laaja leipätekstiin.